



Universidad
Francisco de
Vitoria

UFV Madrid

UNIVERSIDAD FRANCISCO DE VITORIA

ESCUELA POLITÉCNICA SUPERIOR

GRADO EN INGENIERÍA MATEMÁTICA

MEMORIA PROYECTO INTEGRADOR

MODALIDAD INGENIERÍA

**Detección de fraude en transacciones financieras
mediante modelos de clasificación supervisada**

Adrián Herrera Aguilera, Carlota Pons-Fuster Gallardo, Jaime Rodríguez Contreras

Convocatoria de mayo 2026

CALIFICACIÓN DEL PROYECTO FINAL DE GRADO

CUALITATIVA:	
NUMÉRICA:	

Conforme Presidente:	Conforme Secretario:
Fdo.:	Fdo.:

Conforme Vocal:	Conforme Vocal:	Conforme Vocal:
Fdo.:	Fdo.:	Fdo.:

Lugar y fecha: Pozuelo de Alarcón, a ____ de _____ de 202__

Resumen

El crecimiento de las transacciones digitales y de los métodos de pago electrónicos ha provocado también un aumento de las actividades fraudulentas en el ámbito financiero. Debido a esto, la detección automática de fraude se ha convertido en una necesidad importante para las entidades financieras, ya que permite reducir pérdidas económicas y mejorar la seguridad de las operaciones.

Este proyecto tiene como objetivo desarrollar y comparar dos modelos de clasificación supervisada para la detección de fraude en transacciones financieras: Regresión Logística y K-Nearest Neighbors (KNN). Para ello, se trabaja con un conjunto de datos reales de transacciones bancarias etiquetadas como legítimas o fraudulentas.

Una vez preparados los datos, se implementan ambos algoritmos y se evalúa su rendimiento mediante distintas métricas de clasificación, como accuracy, precisión, recall, F1-score y AUC-ROC, prestando especial atención a la capacidad de detectar correctamente las transacciones fraudulentas. Finalmente, se comparan los resultados obtenidos con el objetivo de analizar las diferencias entre ambos enfoques y determinar cuál ofrece un mejor rendimiento en un problema real de detección de fraude financiero.

Palabras claves

Fraude financiero, detección de fraude, Machine Learning, clasificación supervisada, Regresión Logística, K-Nearest Neighbors.

Abstract

The growth of digital transactions and electronic payment methods has also led to an increase in fraudulent activities within the financial sector. As a result, automatic fraud detection has become an important necessity for financial institutions, as it helps reduce economic losses and improve the security of financial operations.

The aim of this project is to develop and compare two supervised classification models for fraud detection in financial transactions: Logistic Regression and K-Nearest Neighbors (KNN). To achieve this, a real dataset of banking transactions labelled as legitimate or fraudulent is used.

Once the data has been prepared, both algorithms are implemented and their performance is evaluated using different classification metrics, such as accuracy, precision, recall, F1-score and AUC-ROC, paying special attention to the ability to correctly detect fraudulent transactions. Finally, the results obtained are compared in order to analyse the differences between both approaches and determine which model offers better performance in a real financial fraud detection problem.

Keywords

Financial fraud, Machine Learning, supervised classification, Logistic Regression, K-Nearest Neighbors, fraud detection.

Índice de Contenidos

1.	Introducción.....	1
2.	Investigación previa.....	3
2.1.	Contextualización del fraude financiero en entornos digitales	4
2.2.	Factores y escenarios del fraude financiero.....	5
2.3.	Técnicas de detección de fraude: estado del arte metodológico	6
2.3.1.	MINERÍA DE DATOS Y ANÁLISIS DE DATOS	6
2.3.2.	MACHINE LEARNING SUPERVISADO.....	7
2.3.3.	MODELOS RELACIONALES Y BASADOS EN GRAFOS	7
2.3.4.	MODELOS PROBABILÍSTICOS Y SECUENCIALES.....	8
2.4.	Estudios previos y resultados en detección de fraude.....	8
2.5.	Síntesis.....	9
3.	Objetivos.....	13
3.1.	Objetivo general	13
3.2.	Lista de objetivos específicos	13
4.	Plan de Desarrollo del Proyecto	15
4.1.	Metodología	15
4.1.1.	SAMPLE (MUESTREO).....	15
4.1.2.	EXPLORE (EXPLORACIÓN).....	16
4.1.3.	MODIFY (MODIFICACIÓN).....	16
4.1.4.	MODEL (MODELADO)	16
4.1.5.	ASSESS (EVALUACIÓN).....	17
4.2.	Tecnologías	17
4.3.	Plan de desarrollo del proyecto	18
4.3.1.	PT1: ANÁLISIS Y DEFINICIÓN DEL PROBLEMA	18
4.3.2.	PT2: DESARROLLO DEL MODELO MATEMÁTICO.....	19
4.3.3.	PT3: IMPLEMENTACIÓN Y ANÁLISIS DE RESULTADOS	20
4.4.	Plan de trabajo.....	20
4.5.	Recursos.....	21

4.6.	Condicionantes y limitaciones	21
5.	Desarrollo de la Solución Técnica.....	23
5.1.	Descripción del conjunto de datos.....	23
5.2.	Análisis inicial de las variables	25
5.3.	Análisis del desbalance de clases	25
5.4.	Preprocesamiento de los datos	26
5.4.1.	ESCALADO DE LA VARIABLE AMOUNT.....	26
5.4.2.	ELIMINACIÓN DE LA VARIABLE TIME	27
5.4.3.	SEPARACIÓN ENTRE VARIABLES INDEPENDIENTES Y OBJETIVO	27
5.5.	Balanceo del conjunto de datos.....	28
5.6.	División del conjunto en entrenamiento y prueba	29
5.7.	Modelo de Regresión Logística	30
5.8.	Modelo de K-Nearest Neighbors.....	30
5.9.	Evaluación de los modelos	31
5.10.	Mejora de los modelos finales	32
6.	Resultados	35
6.1.	Resultados del modelo de regresión logística	35
6.2.	Resultados del modelo K-Nearest neighbors.....	36
6.3.	Comparación de modelos	38
6.4.	Análisis de matrices de confusión.....	39
6.5.	Curva ROC y capacidad discriminativa	40
6.6.	Análisis crítico de los resultados	41
7.	Conclusiones.....	42
8.	Bibliografía.....	45
	Anexo: Código	55

Índice de Tablas

Tabla 1: Temas y técnicas importantes investigadas	11
Tabla 2: Clases y su significado.....	24
Tabla 3: Características de las variables.....	24
Tabla 4: Métricas empleadas y sus utilidades	26
Tabla 5: Separación de variables independientes y objetivo	28
Tabla 6: Proporción tras balanceo de datos	28
Tabla 7: División en entrenamiento y prueba.....	29
Tabla 8: Estructura de una matriz de confusión	32
Tabla 9: Resultados del modelo con Regresión Logística.....	36
Tabla 10: Resultados del modelo con KNN	37

Índice de Figuras

Figura 1: Diagrama de Gantt 1	20
Figura 2: Diagrama de Gantt 2	21
Figura 3: Comparación entre ambos modelos basada en recall y precisión.....	38
Figura 4: Análisis de las matrices de confusión de ambos modelos	39
Figura 5: Comparación de modelos con la curva ROC	40

Índice de Ecuaciones

Ecuación 1: Probabilidad de fraude en la Regresión Logística.....	19
Ecuación 2: Distancia euclídea empleada en KNN.....	19
Ecuación 3: Fórmula de estandarización	27
Ecuación 4: Fórmulas de métricas de clasificación: accuracy, precision, recall, F1-score	32

Lista de Acrónimos

Acrónimo	Significado
NFT	Non-Fungible Token
Et al	Y otros
KNN	K-Nearest Neighbors
SEMMA	Sample, Explore, Modify, Model, Asses
AUC	Area Under the Curve
ROC	Receiver Operating Characteristic

1. INTRODUCCIÓN

La transformación digital del sistema financiero ha provocado un incremento exponencial en el número de transacciones electrónicas realizadas diariamente. El uso generalizado de tarjetas bancarias, pagos móviles y plataformas digitales ha facilitado las operaciones económicas tanto para usuarios como para entidades financieras. Sin embargo, este avance tecnológico también ha generado nuevos escenarios de riesgo relacionados con el fraude financiero, especialmente en entornos donde las transacciones se realizan de forma automatizada y sin interacción presencial.

En este contexto, la detección de fraude se ha convertido en uno de los principales desafíos dentro del ámbito financiero y tecnológico. Las operaciones fraudulentas representan una proporción muy pequeña respecto al total de transacciones, lo que dificulta enormemente su identificación. Además, los patrones de fraude evolucionan constantemente, adaptándose a los sistemas de seguridad existentes y obligando a desarrollar mecanismos de detección cada vez más eficaces y automatizados.

Ante esta situación, las técnicas de análisis de datos y aprendizaje automático han adquirido una gran relevancia. Los modelos de clasificación supervisada permiten analizar grandes volúmenes de información y detectar comportamientos anómalos que podrían corresponder a actividades fraudulentas. Gracias a estos métodos, es posible mejorar la capacidad de detección y reducir el impacto económico asociado a este tipo de delitos financieros.

El proyecto se centra en el desarrollo e implementación de un sistema de detección de fraude en transacciones financieras mediante técnicas de Machine Learning supervisado. En concreto, se estudian y comparan dos modelos de clasificación: Regresión Logística y K-Nearest Neighbors (KNN). Ambos enfoques representan metodologías diferentes dentro del aprendizaje automático: uno basado en estimaciones probabilísticas y otro fundamentado en la similitud entre observaciones. El objetivo principal consiste en analizar su capacidad para diferenciar transacciones legítimas y fraudulentas a partir de un conjunto de datos reales.

Para ello, se ha utilizado el dataset “Credit Card Fraud Detection”, disponible en la plataforma Kaggle, aplicando distintas fases de preprocesamiento, balanceo de clases y evaluación mediante métricas adaptadas al problema del fraude financiero, como precisión, recall, F1-score y AUC-ROC. Especialmente, se presta atención al recall debido a la importancia que tiene minimizar los falsos negativos en este tipo de sistemas.

La memoria se estructura en varios apartados. En primer lugar, se realiza una investigación previa sobre el fraude financiero y las principales técnicas utilizadas actualmente para su detección. Posteriormente, se presentan los objetivos y la planificación del proyecto, junto con la metodología empleada para el desarrollo. A continuación, se describe el proceso técnico seguido para el tratamiento de los datos y la implementación de los modelos. Finalmente, se analizan y comparan los resultados obtenidos, extrayendo conclusiones sobre la eficacia de los modelos estudiados y sus posibles aplicaciones en entornos reales de detección de fraude.

2. INVESTIGACIÓN PREVIA

En esta parte de la memoria se presenta una intensa revisión del estado actual del conocimiento en el ámbito de la detección de fraude en transacciones financieras digitales. Diversos estudios coinciden en que la digitalización del sistema financiero ha transformado en gran medida el contexto en el que se producen las transacciones, incrementando tanto su volumen como su complejidad [2]. Este proceso ha venido acompañado de un aumento significativo de actividades fraudulentas, especialmente en entornos digitales, donde la automatización y la ausencia de interacción presencial dificultan los mecanismos tradicionales de control [7].

La investigación existente ha señalado que la evolución del fraude está vinculada a los cambios tecnológicos y a la aparición de nuevos entornos financieros digitales. En particular, el desarrollo de criptomonedas y activos digitales ha ampliado los escenarios en los que pueden producirse actividades fraudulentas [1]. Asimismo, se ha demostrado que el fraude no responde a un único patrón, sino que depende de múltiples factores relacionados con el comportamiento del usuario, las características de la transacción y el contexto operativo [8].

Desde una perspectiva económica, la investigación también ha abordado el impacto del fraude en términos de asignación del riesgo y responsabilidad entre los distintos agentes del sistema financiero. Estudios como el de Rodríguez Zárate [3] destacan que la distribución de la responsabilidad influye en el diseño de los sistemas de prevención y en la implementación de mecanismos de detección. En este sentido, se valora la necesidad de considerar no solo la precisión de los modelos, sino también el coste asociado a los errores de clasificación, sobre todo en situaciones donde el fraude es solo una pequeña parte del total de transacciones [5].

En este contexto, la detección de fraude ha evolucionado hacia el uso de técnicas avanzadas de análisis de datos, destacando la minería de datos y el aprendizaje automático como herramientas fundamentales para el procesamiento de grandes volúmenes de información [4], [13]. A lo largo de este apartado se analizan más en profundidad las principales formas de abordar el problema, así como los resultados obtenidos en estudios previos, con el objetivo de fundamentar el enfoque adoptado en el proyecto.

2.1. CONTEXTUALIZACIÓN DEL FRAUDE FINANCIERO EN ENTORNOS DIGITALES

La digitalización del sistema financiero ha supuesto un cambio de estructura en la naturaleza de las transacciones, caracterizado por un incremento en su volumen, velocidad y complejidad. Este proceso ha sido impulsado por la normalización general de medios de pago electrónicos y por la expansión del comercio digital, generando un entorno en el que la mayoría de las operaciones se realizan sin interacción presencial [2]. Y es justo por esto que los mecanismos tradicionales de control han perdido eficacia ante el aumento en la complejidad de las actividades fraudulentas.

Diversos estudios han identificado la pandemia del COVID-19 como un punto de inflexión en esta evolución. Durante este periodo se aceleró el uso de servicios financieros digitales, lo que amplió la superficie de exposición al fraude [7]. En concreto, al aumentar las transacciones a distancia, se han perdido muchas de las formas habituales de verificación, por lo que ahora la detección depende sobre todo del análisis de los datos de las transacciones.

De esta forma el fraude se convierte en un fenómeno adaptativo, cuya detección requiere modelos capaces de capturar cambios en el comportamiento a lo largo del tiempo. Tal como señalan Compagnino et al. [4], los sistemas de detección deben enfrentarse a entornos no estacionarios, donde los patrones aprendidos pueden quedarse desactualizados en poco tiempo. Esto supone una limitación importante para muchos métodos tradicionales, sobre todo los que se basan en reglas fijas o modelos demasiado rígidos.

Además, la evidencia basada en datos reales muestra que la complejidad del fraude no reside solo en su evolución temporal, sino también en la interacción entre múltiples factores. Díaz Agudelo et al. [8] destacan que el comportamiento del usuario, el contexto de la transacción y las condiciones del entorno digital influyen conjuntamente en la probabilidad de fraude. Sin embargo, muchos de los enfoques actuales se centran sobre todo en mejorar la precisión de las predicciones sin tener en cuenta el impacto económico de las decisiones que se toman.

Todo este análisis señala a la falta de integración entre modelos predictivos y criterios de gestión del riesgo. Este trabajo se centra en la aplicación de modelos sobre un conjunto de datos de transacciones financieras con el objetivo de identificar operaciones potencialmente fraudulentas. El análisis se orienta a comparar el rendimiento de ambos enfoques en términos de predicción sobre datos reales, permitiendo identificar sus diferencias en un contexto práctico de clasificación binaria.

2.2. FACTORES Y ESCENARIOS DEL FRAUDE FINANCIERO

No se puede analizar el fraude financiero únicamente como un conjunto de eventos aislados. Diversos estudios han identificado variables clave que influyen en la probabilidad de que una transacción sea fraudulenta, incluyendo características del usuario, del contexto de la transacción y del entorno tecnológico [8].

Entre los factores más relevantes destacan:

- Comportamiento del usuario: patrones de gasto, frecuencia de transacciones o localización geográfica.
- Características de la transacción: importe, hora, tipo de comercio o canal.
- Entorno digital: uso de dispositivos desconocidos, direcciones IP sospechosas o cambios en el comportamiento habitual.

El estudio de Díaz Agudelo et al. [8] demuestra que la ejecución del fraude está condicionada tanto por factores internos: motivación del atacante; como por factores externos: debilidades del sistema; lo que refuerza la necesidad de modelos capaces de integrar múltiples variables.

Por otro lado, el fraude se ha extendido más allá del ámbito bancario tradicional hacia nuevos ecosistemas digitales. El desarrollo de tecnologías como criptomonedas y NFTs ha generado nuevos escenarios de riesgo descentralizados y con ausencia de intermediarios [1]. Aunque estos entornos ofrecen más claridad también pueden facilitar el fraude si no hay buenos mecanismos de control.

Económicamente, la responsabilidad del fraude entre usuarios y entidades financieras es un elemento clave. Rodríguez Zárate [3] analiza cómo el riesgo puede recaer sobre distintas partes según el marco legal y operativo, lo que influye directamente en el diseño de los sistemas de prevención.

Asimismo, el fraude implica un coste económico significativo que no solo incluye pérdidas directas, sino también costes asociados a los incidentes. Debido a esto la evaluación de los sistemas de detección debe tener en cuenta el impacto económico de los errores de clasificación, diferenciando entre falsos positivos y falsos negativos.

2.3. TÉCNICAS DE DETECCIÓN DE FRAUDE: ESTADO DEL ARTE METODOLÓGICO

La detección de fraude financiero ha evolucionado significativamente con el desarrollo de técnicas de análisis de datos y aprendizaje automático. Por el volumen y la complejidad de las transacciones, los investigadores coinciden en que los métodos tradicionales basados en reglas son insuficientes y resulta necesario el uso de modelos automatizados [4].

2.3.1. MINERÍA DE DATOS Y ANÁLISIS DE DATOS

La minería de datos es una de las metodologías más usadas para detectar fraude financiero, ya que permite analizar grandes cantidades de información de transacciones para encontrar patrones útiles para clasificar operaciones. Rizki et al. [10] demuestran que el análisis estructurado de variables financieras en empresas públicas permite identificar anomalías que coinciden con posibles fraudes, lo que demuestra la utilidad de estas técnicas en entornos con datos complejos y variados.

El proceso de minería de datos no se limita a la extracción de información, sino que depende de las fases previas de preparación del dataset. Etapas como la limpieza de datos, la selección de variables y la transformación de atributos son determinantes para el rendimiento de los modelos de clasificación. La selección de variables relevantes permite reducir ruido y mejorar la capacidad de los algoritmos para adaptarse a nuevos datos, lo cual es especialmente importante en problemas de fraude debido al elevado desbalance entre clases.

Udeh et al. [22] destacan el papel del Big Data en esta área, remarcando que el incremento del volumen de datos transaccionales mejora la detección de patrones complejos. Aunque este aumento de información no implica una mejora en la calidad del modelo ya que datos irrelevantes pueden afectar negativamente a la predicción. Este aspecto es muy relevante en sistemas de detección de fraude donde diferenciar entre transacciones legítimas y fraudulentas depende de señales muy sutiles.

Además de lo observado, la principal limitación de la minería de datos consiste en que los patrones extraídos pueden no adaptarse a cambios en los comportamientos lo que obliga a combinar estas técnicas con modelos de aprendizaje automático supervisado. En este proyecto, esto justifica su uso como un paso previo para preparar y organizar los datos antes de aplicar los modelos de clasificación.

2.3.2. MACHINE LEARNING SUPERVISADO

El aprendizaje automático supervisado es la metodología predominante generalizada en la detección de fraude. Estos modelos se entrenan utilizando datos etiquetados en los que cada transacción se clasifica como fraudulenta o legítima [9].

Entre los algoritmos más utilizados se encuentran:

- Regresión logística
- K-Nearest Neighbors
- Árboles de decisión
- Random Forest
- Redes neuronales

Dornadula y Geetha [12] evaluaron diferentes algoritmos en detección de fraude con tarjetas de crédito, obteniendo resultados de precisión superiores al 90 % en modelos como Random Forest y redes neuronales, mientras que la regresión logística mostró un rendimiento ligeramente inferior pero mayor interpretabilidad. Estos resultados exponen que no existe un único modelo óptimo absoluto, sino que el rendimiento depende del equilibrio entre precisión e interpretación que se busque en el sistema.

Por su parte, Dávila-Morán et al. [13] destacan que modelos como KNN pueden ofrecer buenos resultados en datasets con estructuras claras, aunque su rendimiento depende del tamaño de los datos y de la selección de variables.

Uno de los principales problemas en este ámbito es el desbalanceo de clases porque las transacciones fraudulentas representan un porcentaje muy reducido del total de transacciones. Esto obliga a aplicar técnicas específicas como sobremuestreo, submuestreo o ajuste de umbrales de decisión [9], [13].

2.3.3. MODELOS RELACIONALES Y BASADOS EN GRAFOS

Los modelos basados en grafos han ganado relevancia en los últimos años debido a su capacidad para representar relaciones entre entidades. En lugar de analizar transacciones de forma aislada, lo que hacen estos modelos es considerar la estructura de interacción entre usuarios, cuentas y dispositivos.

Van Vlasselaer et al. [17] proponen el modelo APATE que utiliza información relacional para detectar fraude en tarjetas de crédito, logrando mejoras significativas en la precisión respecto a modelos tradicionales. En sus experimentos se muestran mejoras frente a

enfoques basados en atributos transaccionales, observando incrementos en métricas de detección como la precisión y el recall. En particular, el modelo APATE consigue reducir los falsos negativos lo que resulta bastante favorable en contextos financieros donde la omisión de una transacción fraudulenta implica un mayor impacto económico que la clasificación errónea de una operación legítima.

2.3.4. MODELOS PROBABILÍSTICOS Y SECUENCIALES

Los enfoques probabilísticos modelan explícitamente la incertidumbre asociada a cada operación. Las redes bayesianas y los modelos secuenciales permiten representar dependencias causales y evolución temporal del comportamiento del usuario en entornos financieros, siendo utilizados en distintos trabajos para capturar patrones de transacción dependientes del historial y del contexto [4], [13], [17]. Su principal ventaja se aprecia en que generan probabilidades interpretables, facilitando la integración en sistemas de decisión basados en umbrales de riesgo en lugar de clasificaciones binarias [3], [11].

A pesar del desarrollo de múltiples enfoques metodológicos para la detección de fraude financiero, la literatura identifica una serie de desafíos que condicionan su eficacia [9], [13]. Entre ellos destacan:

- El desbalanceo extremo de clases: debido a que las operaciones fraudulentas representan un porcentaje reducido del total.
- El coste asimétrico de los errores de clasificación: ya que no detectar una operación fraudulenta implica pérdidas económicas directas, mientras que bloquear una transacción legítima puede generar costes operativos y afectar a la experiencia del usuario [4], [14].

Asimismo, la creciente complejidad de algunos modelos plantea dificultades en ciertos términos. En conjunto, estos factores muestran que la detección de fraude constituye un problema dinámico que requiere integrar precisión predictiva y gestión cuantitativa del riesgo.

2.4. ESTUDIOS PREVIOS Y RESULTADOS EN DETECCIÓN DE FRAUDE

Estudios recientes muestran que el uso de técnicas de aprendizaje automático mejora en gran cantidad la detección de fraude frente a métodos tradicionales, especialmente en escenarios con grandes volúmenes de datos y patrones no lineales [9], [13].

Faridpour y Moradi [15] desarrollaron un modelo basado en redes neuronales multicapa aplicada a la detección de transacciones fraudulentas, obteniendo mejoras notorias en la capacidad de generar modelos y reduciendo el error de clasificación. En sus experimentos, destacan que la introducción de capas ocultas permite capturar relaciones complejas entre variables, lo cual desemboca en una mejora del rendimiento global del sistema, especialmente en datasets con alta variabilidad.

De un estilo similar, Ranganatha y Mustafa [14] propusieron un modelo híbrido que combina redes neuronales con tecnologías blockchain en el contexto de transacciones móviles. Sus resultados mostraron mejoría en la eficiencia del sistema de detección, sobre todo en la reducción de fraudes no detectados.

Respecto modelos más simples, Dornadula y Geetha [12] analizaron el comportamiento de algoritmos clásicos como la regresión logística y K-Nearest Neighbors en problemas de fraude con tarjetas de crédito. Sus resultados mostraban que ambos modelos pueden alcanzar niveles de precisión elevados cuando los datos han sido correctamente preprocesados con valores superiores al 85–90 % de precisión. En particular, la regresión logística destaca por su estabilidad y capacidad de interpretación probabilística, mientras que KNN funciona bien para detectar patrones cercanos en los datos, aunque es más costoso en términos de cálculo cuando se trabaja con grandes volúmenes de información.

Por otro lado, estudios como el de Tustón Fuentes y Macías Arias [9] tienen claro que no existe un modelo totalmente óptimo para la detección de fraude, ya que el rendimiento depende del contexto del problema, la calidad de los datos y el objetivo del sistema. En este sentido, los estudios muestran una tendencia clara a combinar modelos fáciles de interpretar con otros más complejos, con el objetivo de equilibrar la precisión, la capacidad de escalar y la facilidad para entender los resultados en entornos financieros reales.

2.5. SÍNTESIS

A partir de la comprensión de esta información y su reflexión, se concluye que la detección de fraude financiero es un problema complejo que requiere la integración de técnicas de análisis de datos, aprendizaje automático y gestión del riesgo.

Es verdad que los modelos avanzados como redes neuronales o algoritmos híbridos ofrecen altos niveles de precisión, pero presentan limitaciones en interpretabilidad, complejidad computacional y necesidad de grandes volúmenes de datos.

En este contexto, las investigaciones sugieren que modelos más simples como la regresión logística y K-Nearest Neighbors pueden ser una alternativa eficaz cuando se cuenta con datos organizados y se necesita que los resultados sean fáciles de interpretar [12], [13].

La regresión logística permite estimar directamente la probabilidad de que una transacción sea fraudulenta, lo que facilita la toma de decisiones basada en umbrales de riesgo ajustables según el contexto. Además es un modelo muy utilizado en problemas de clasificación binaria dentro del ámbito financiero, ya que permite analizar el peso de cada variable en la predicción del fraude y comprender su influencia en el resultado final [9], [12], [13].

Por otra parte, K-Nearest Neighbors aporta una aproximación basada en la similitud entre observaciones, asignando la clase de una transacción en función del comportamiento de sus vecinos más cercanos; permite capturar patrones locales en los datos que pueden no ser evidentes para modelos lineales, lo que resulta muy útil cuando existen subgrupos de comportamiento o estructuras no lineales [12], [15].

En conjunto, ambos modelos pueden ser complementarios dentro de la detección de fraude: uno basado en la interpretación probabilística del problema y otro en la detección de similitudes locales en los datos, lo que permite dar equilibrio en el sistema analizado [9], [13].

En consecuencia a esto, el desarrollo de este proyecto estará orientado a la implementación y comparación de ambos modelos, con el objetivo de evaluar su rendimiento en la detección de fraude y analizar su impacto.

Importancia (Tema/Técnica)	Título de la fuente	Objetivo del estudio	Relación y aportación al proyecto
Tema	Financial Fraud: A Literature Review	Revisión de los tipos de fraude financiero.	Permite conocer de manera general en que consiste el fraude bancario digital
Tema	The Economics of Information Security	Análisis económico del fraude e importancia de la seguridad.	Conocer e integrar optimización del riesgo y análisis coste-beneficio.
Tema	Responsabilidad bancaria frente al fraude electrónico	Estudio de la responsabilidad económica de las entidades financieras.	Concienciar de la necesidad de modelos de predicción efectivos en banca.
Tema	Big Data in Detecting and Preventing Financial Fraud	Analizar el papel del big data en la detección del fraude digital.	Sustenta el uso de grandes volúmenes de datos transaccionales.
Tema	A Survey of Data Analytics for Fraud Detection	Revisión de técnicas analíticas en fraude.	Conecta el problema financiero con el estado del arte en analítica.
Técnicas	Calculation of Expected Loss	Cálculo de pérdida esperada mediante	Base matemática para modelar riesgo

	Using Probabilistic Hazard Analysis	modelos probabilísticos.	esperado en transacciones.
Técnicas	Hidden Markov Models	Aplicación de modelos de Markov en modelado de secuencias.	Aplicable a detección de patrones no comunes en secuencias de transacciones.
Técnicas	Graph Neural Networks for Financial Fraud Detection	Conocer técnicas de grafos aplicadas al fraude financiero.	Permite modelar relaciones entre cuentas y redes de fraude.
Técnicas	Hybrid Deep Learning: Mix-of-Experts Approach	Modelo híbrido avanzado para detección de fraude.	Sirve como referencia comparativa frente al modelo probabilístico propuesto.

Tabla 1: Temas y técnicas importantes investigadas

3. OBJETIVOS

3.1. OBJETIVO GENERAL

El objetivo del proyecto es diseñar e implementar un sistema de clasificación supervisada, basados en K-Nearest Neighbors y regresión logística, para la detección de fraude en transacciones bancarias digitales, compararlos para ver qué modelo tiene mejor rendimiento predictivo, y determinar que variables son las que más influyen en la clasificación de operaciones fraudulentas.

3.2. LISTA DE OBJETIVOS ESPECÍFICOS

1-Analizar cómo funciona el fraude en transacciones digitales, informándonos y entendiendo cuáles son los tipos más comunes y sus patrones característicos de los datos.

2-Seleccionar un conjunto de datos analizando las variables que más relevantes, para interpretar qué factores influyen más en la detección de fraude.

3-Implementar dos modelos de clasificación en Python, el primero basado en K-Nearest Neighbors y el segundo en regresión logística, y evaluar su rendimiento mediante métricas adecuadas, para minimizar el riesgo económico.

4-Comparar ambos modelos de predicción para contrastar resultados, y analizar qué modelo nos permite una mayor estabilidad y un mejor rendimiento.

4. PLAN DE DESARROLLO DEL PROYECTO

4.1. METODOLOGÍA

Para el desarrollo del proyecto se ha seleccionado la metodología SEMMA (Sample, Explore, Modify, Model, Assess). Se ha elegido esta metodología ya que proporciona una estructura clara para trabajar con grandes volúmenes de datos, y es eficaz para construir modelos predictivos fiables.

En particular, en el contexto de la detección de fraude en transacciones bancarias, esta metodología resulta especialmente adecuada debido a que facilita el tratamiento de problemas típicos en fraude financiero, como el desbalanceo de clases. Además, el problema requiere partir de un conjunto de datos amplio, analizar sus características y entrenar modelos capaces de distinguir entre operaciones legítimas y fraudulentas.

4.1.1. SAMPLE (MUESTREO)

En esta fase se selecciona y organiza el conjunto de datos con el que se va a trabajar. En este proyecto se parte de un dataset de transacciones financieras etiquetadas, donde cada operación pertenece a una de las dos clases posibles: legítima o fraudulenta. Esta etapa es importante porque en problemas de fraude suele existir un fuerte desbalanceo de clases, ya que las transacciones fraudulentas representan una parte muy pequeña del total. Por ello, se consideran técnicas de muestreo que permitan equilibrar el dataset y mejorar el rendimiento de los modelos.

4.1.2. EXPLORE (EXPLORACIÓN)

Se realiza un análisis exploratorio de los datos con el objetivo de comprender su estructura, identificar patrones y detectar posibles problemas que puedan afectar al modelado.

Se estudian aspectos como la distribución de las variables, la presencia de valores atípicos, la relación entre atributos y la proporción entre clases. También se analiza la relevancia de las distintas variables para determinar cuáles pueden aportar más información en la detección del fraude.

4.1.3. MODIFY (MODIFICACIÓN)

En esta etapa se transforman y preparan los datos para que puedan ser utilizados correctamente por los algoritmos. Aquí se lleva a cabo la limpieza del conjunto de datos, la normalización o escalado de variables cuando sea necesario, la selección de características relevantes y el tratamiento del desbalanceo de clases.

Esta etapa es especialmente importante en este proyecto, ya que tanto KNN como Regresión Logística pueden verse afectados por la escala de las variables y por una distribución muy desigual entre fraude y no fraude.

Se aplican las siguientes transformaciones:

- Eliminación de la variable Time, al no aportar información relevante para el modelo.
- Escalado de variables mediante StandardScaler, necesario especialmente para algoritmos basados en distancia como KNN.
- Separación del dataset en conjunto de entrenamiento y test.

4.1.4. MODEL (MODELADO)

Una vez preparados los datos, se procede a construir los modelos predictivos. En este proyecto se implementan dos algoritmos de clasificación supervisada:

Regresión Logística, seleccionada por su interpretabilidad y por su capacidad de estimar probabilidades de fraude, y K-Nearest Neighbors, elegido por su capacidad para detectar similitudes locales entre transacciones y capturar patrones no lineales.

Durante esta fase se entrenan ambos modelos con los datos preparados y se ajustan sus parámetros para obtener el mejor rendimiento posible.

4.1.5. ASSESS (EVALUACIÓN)

En la última fase se evalúan y comparan los resultados obtenidos por los modelos. Para ello se emplean métricas adecuadas al problema de clasificación binaria y al contexto del fraude financiero, donde el desbalance de clases hace que la accuracy por sí sola no sea suficiente. Por este motivo, además de la exactitud, se consideran métricas como:

- Precisión
- Recall, especialmente importante
- F1-score
- Matriz de confusión

Esta fase permite determinar cuál de los dos modelos ofrece un mejor rendimiento en la detección de fraude y analizar cuál resulta más adecuado según el equilibrio entre capacidad predictiva e interpretabilidad.

4.2. TECNOLOGÍAS

El desarrollo del proyecto se ha llevado a cabo utilizando el lenguaje de programación Python, debido a su amplia utilidad en el ámbito del análisis de datos y el aprendizaje automático, así como por la disponibilidad de librerías especializadas que facilitan la implementación de modelos predictivos.

Para la implementación del sistema de detección de fraude se han empleado las siguientes herramientas y librerías: En primer lugar, Pandas, utilizada para la carga, manipulación y estructuración del dataset de transacciones financieras. Permite gestionar grandes volúmenes de datos de forma eficiente y realizar operaciones como filtrado, selección de variables y creación de subconjuntos. También se ha usado NumPy, empleada para el manejo de estructuras numéricas y operaciones matemáticas necesarias en el procesamiento de los datos. Matplotlib, utilizada para la representación gráfica de resultados, incluyendo curvas ROC y comparaciones entre modelos. La librería Seaborn ha sido empleada para la visualización de matrices de confusión mediante mapas de calor, facilitando la interpretación de los resultados de clasificación. Scikit-learn, que es la librería principal, utilizada para la implementación de los modelos de clasificación y el procesamiento de los datos. En concreto, se han utilizado:

LogisticRegression, para la construcción del modelo de regresión logística orientado a la estimación de probabilidades de fraude. KNeighborsClassifier, para la implementación del modelo KNN basado en la similitud entre transacciones. StandardScaler, para la normalización de las variables, especialmente necesaria en modelos basados en distancia como KNN. Train_test_split, para la división del dataset en conjuntos de entrenamiento y test.

También se han usado métricas de evaluación como la matriz de confusión, métricas de clasificación (precision, recall, F1-score) y AUC-ROC.

4.3. PLAN DE DESARROLLO DEL PROYECTO

El desarrollo del proyecto se organiza en tres paquetes de trabajo principales, definidos de acuerdo con la metodología adoptada y orientados a estructurar de forma secuencial el proceso completo de resolución del problema. Estos paquetes abarcan desde la definición del problema hasta la implementación de los modelos y el análisis de los resultados, permitiendo una organización clara y coherente del desarrollo.

4.3.1. PT1: ANÁLISIS Y DEFINICIÓN DEL PROBLEMA

El primer paquete de trabajo, correspondiente al análisis y definición del problema, tiene como finalidad establecer las bases teóricas, conceptuales y metodológicas sobre las que se apoya el proyecto. En esta fase se lleva a cabo una revisión del estado del arte en detección de fraude financiero, analizando distintos enfoques propuestos en la literatura, especialmente aquellos basados en técnicas de aprendizaje automático y análisis de datos. Esta revisión permite comprender la complejidad del problema, caracterizado por la presencia de patrones no evidentes y por un fuerte desbalanceo entre clases. Asimismo, se procede a la formalización del problema como un caso de clasificación binaria supervisada, definiendo el espacio de variables y la variable objetivo. En esta etapa también se establecen los objetivos específicos del proyecto, así como los criterios de evaluación que se utilizarán en fases posteriores, teniendo en cuenta la naturaleza asimétrica de los errores en la detección de fraude. Este paquete de trabajo resulta fundamental, ya que proporciona el marco de referencia necesario para orientar correctamente el desarrollo técnico del sistema.

4.3.2. PT2: DESARROLLO DEL MODELO MATEMÁTICO

El segundo paquete de trabajo se centra en el desarrollo del modelo matemático y en la preparación de los datos necesarios para su implementación. En esta fase se llevan a cabo diversas tareas de preprocesamiento del dataset, incluyendo la eliminación de variables que no aportan información relevante, la normalización de los datos para garantizar una correcta escala entre variables y el tratamiento del desbalanceo de clases mediante técnicas de submuestreo de la clase mayoritaria. Estas decisiones son clave para mejorar el rendimiento de los modelos y evitar sesgos en el aprendizaje.

Una vez preparados los datos, se procede a la implementación de los modelos de clasificación seleccionados. En el caso de la regresión logística, el modelo se basa en la estimación de la probabilidad de que una observación pertenezca a la clase fraudulenta mediante la función sigmoide:

$$P(y = 1 | x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}$$

Ecuación 1: Probabilidad de fraude en la Regresión Logística

Este enfoque permite interpretar el resultado del modelo como una probabilidad asociada al riesgo de fraude, lo que resulta especialmente útil en contextos financieros.

Por otro lado, el algoritmo K-Nearest Neighbors se basa en la proximidad entre observaciones dentro del espacio de características. Para medir dicha proximidad, se utiliza habitualmente la distancia euclídea entre dos observaciones:

$$d(x_i, x_j) = \sqrt{\sum_{k=1}^n (x_{ik} - x_{jk})^2}$$

Ecuación 2: Distancia euclídea empleada en KNN

A partir de esta distancia, el modelo asigna la clase en función de los vecinos más cercanos, lo que permite capturar patrones locales en los datos. Esta fase constituye el núcleo técnico del proyecto, ya que en ella se construyen los modelos que posteriormente serán evaluados.

4.3.3. PT3: IMPLEMENTACIÓN Y ANÁLISIS DE RESULTADOS

El tercer paquete de trabajo corresponde a la implementación final y al análisis de los resultados obtenidos. En esta etapa se evalúa el rendimiento de los modelos mediante distintas métricas de clasificación, como la precisión, el recall, el F1-score y el AUC, seleccionadas en función de la naturaleza del problema. Se presta especial atención al recall, dado que en el contexto de fraude financiero resulta prioritario minimizar los falsos negativos, es decir, evitar que transacciones fraudulentas no sean detectadas. Además, se emplean herramientas de análisis visual como la matriz de confusión y la curva ROC, que permiten interpretar de forma más detallada el comportamiento de los modelos y comparar su capacidad discriminativa. A partir de estos resultados, se realiza una comparación entre los modelos implementados, analizando sus fortalezas y limitaciones, así como su estabilidad frente a los datos. Este análisis permite extraer conclusiones relevantes sobre la eficacia de cada enfoque y valorar su posible aplicación en entornos reales de detección de fraude.

4.4. PLAN DE TRABAJO

Para la planificación del proyecto se ha elaborado un diagrama de Gantt, en el que se representan las diferentes fases del trabajo y su duración.




Figura 1: Diagrama de Gantt 1




Figura 2: Diagrama de Gantt 2

4.5. RECURSOS

Para la realización del proyecto se ha trabajado principalmente con un conjunto de datos de transacciones financieras ya existente, que ha servido como base para el análisis y el entrenamiento de los modelos.

Además, se ha utilizado Python para desarrollar el código e implementar los modelos.

Por último, uno de los recursos más importantes ha sido el tiempo dedicado al proyecto, para implementar y analizar los resultados.

4.6. CONDICIONANTES Y LIMITACIONES

Uno de los condicionantes es que se ha trabajado con un conjunto de datos que ya existía por la complejidad que hubiese supuesto recoger esa información por medios propios, entonces no se disponía de tanta variedad de variables a estudiar.

Otra de las dificultades ha sido que había muchísima diferencia entre el porcentaje de transacciones fraudulentas y normales, siendo un 0.17% fraudulentas, por lo que se ha tenido que modificar los datos para equilibrarlos, dejando de ser tan realista. Se ha tomado

todos los datos fraudulentos y el triple de normales, para reducir el número de estas últimas transacciones; y consiguiendo así, una proporción de $\frac{1}{4}$ fraude y un $\frac{3}{4}$ normal.

Además, los resultados dependen del conjunto de datos utilizado y de cómo se ha dividido en entrenamiento y test, por lo que podrían variar si se trabajara con otros datos o con más pruebas.

Por último, existen muchos modelos que no se han incluido, por lo que no ha sido posible profundizar en otras técnicas más completas y avanzadas que podrían ofrecer un mejor rendimiento.

5. DESARROLLO DE LA SOLUCIÓN TÉCNICA

En este apartado se describe el proceso para el desarrollo de la solución técnica del proyecto. El objetivo principal es desarrollar un sistema de clasificación supervisada que pueda diferenciar entre operaciones fraudulentas y legítimas usando un conjunto de datos financieros.

Para esto, se toma un conjunto de datos de transacciones bancarias con etiquetas, se examinan sus variables y se utilizan métodos de preprocesamiento y balanceo. Finalmente, se entrenan dos modelos de clasificación: K-Nearest Neighbors y Regresión Logística. Los dos modelos se analizan más adelante usando métricas apropiadas para los problemas de fraude, con un enfoque particular en el recall, puesto que es crucial reducir al mínimo los falsos negativos en este contexto; es decir, aquellos fraudes que el modelo no logra identificar.

La estructura seguida en este apartado busca detallar el análisis llevado a cabo sobre los datos y los modelos, siguiendo un planteamiento donde el desarrollo no se limita a explicar el plan de trabajo, sino que profundiza en el tratamiento real de la base de datos, las variables utilizadas, las transformaciones aplicadas y la evaluación de los modelos

5.1. DESCRIPCIÓN DEL CONJUNTO DE DATOS

El conjunto de datos utilizado en este proyecto procede de la plataforma Kaggle y corresponde al dataset conocido como *Credit Card Fraud Detection*. Este conjunto recoge transacciones realizadas con tarjeta de crédito, clasificadas según si son operaciones legítimas o fraudulentas. La elección de esta base de datos se debe a que contiene transacciones reales previamente etiquetadas, lo que permite plantear el problema como una tarea de clasificación supervisada binaria.

Cada fila del dataset representa una transacción individual, mientras que las columnas contienen información numérica asociada a dicha operación. El objetivo del proyecto es construir un modelo capaz de predecir si una transacción es fraudulenta o legítima a partir de sus características.

La variable objetivo del dataset es Class, que puede tomar dos valores:

VALOR DE CLASS	SIGNIFICADO
0	Transacción legítima
1	Transacción fraudulenta

Tabla 2: Clases y su significado

Por tanto, el modelo debe aprender a partir de ejemplos ya etiquetados para poder clasificar nuevas transacciones. El dataset original contiene las siguientes variables:

VARIABLE	TIPO	DESCRIPCIÓN	USO EN EL MODELO
Time	Numérica	Tiempo transcurrido entre cada transacción y la primera transacción del dataset.	Eliminada
V1-V28	Numéricas	Representan información anonimizada de la transacción.	Utilizadas
Amount	Numérica	Importe económico de la transacción.	Utilizadas tras escalado
Class	Binaria	Variable objetivo: indica si la transacción es fraudulenta o legítima.	Variable dependiente

Tabla 3: Características de las variables

Una característica importante del dataset es que las variables V1 a V28 no tienen una interpretación directa, ya que han sido previamente transformadas para proteger la privacidad de los datos originales. Esto significa que no se puede saber con exactitud si una variable representa el país, el comercio, el dispositivo, el tipo de operación o el comportamiento del usuario. Sin embargo, aunque no puedan interpretarse de esa forma, sí pueden utilizarse matemáticamente para entrenar los modelos. Estas variables contienen patrones numéricos que permiten diferenciar, en mayor o menor medida, entre transacciones legítimas y fraudulentas.

Esto implica una gran limitación desde el punto de vista interpretativo, ya que el análisis no puede centrarse en explicar el significado real de cada variable, sino en estudiar su influencia estadística dentro del modelo. En consecuencia, la base de datos resulta adecuada para este proyecto porque tiene tres características fundamentales: contiene transacciones financieras reales, dispone de una variable objetivo claramente definida y permite aplicar modelos de clasificación supervisada para detectar posibles operaciones fraudulentas.

5.2. ANÁLISIS INICIAL DE LAS VARIABLES

Antes de aplicar los modelos, se analiza la estructura del conjunto de datos y el papel de cada variable dentro del problema:

- La variable *Class* es la más importante, ya que define la etiqueta que se quiere predecir. Al ser una variable binaria permite formular el problema como una clasificación supervisada de dos clases: fraude y no fraude.
- La variable *Amount* representa el importe de la transacción. Esta variable sí tiene interpretación directa y puede ser relevante, ya que determinados fraudes pueden estar relacionados con importes inusuales, operaciones de importe elevado o movimientos que se alejan del comportamiento habitual. Aunque su escala puede ser muy diferente a la del resto de variables, por lo que necesita ser estandarizada antes de entrenar los modelos.
- La variable *Time* representa el tiempo transcurrido desde la primera transacción registrada. En este proyecto se decidió eliminarla porque no aporta información directa sobre el comportamiento económico de la operación y podría introducir ruido en el modelo. Además el objetivo del proyecto no es analizar la evolución temporal del fraude.
- Las variables *V1* a *V28* representan el núcleo del dataset. Contienen información transformada sobre cada transacción. Estas variables resultan de un proceso de transformación previo, por lo que ya se encuentran en una escala más adecuada que *Amount*. Por esto se mantienen en el modelo y se utilizan como variables predictoras.

Desde el punto de vista del aprendizaje automático, el conjunto de variables independientes queda formado por: $X = \{V1, V2, \dots, V28, Amount\}$; y la variable dependiente queda definida como: $y = Class$; donde $y = 0$ si la transacción es legítima, e $y = 1$ si la transacción es fraudulenta.

5.3. ANÁLISIS DEL DESBALANCE DE CLASES

Uno de los principales problemas del dataset es el fuerte desbalance entre clases. En el conjunto de datos original las transacciones fraudulentas representan aproximadamente un 0,17% del total mientras que la gran mayoría corresponden a operaciones legítimas.

Esto genera una dificultad importante ya que un modelo podría obtener una accuracy muy alto clasificando casi todas las operaciones como legítimas, pero fallando precisamente en la clase más importante: el fraude. Al contener solo un 0,17% de transacciones fraudulentas, un modelo que clasificase todas las operaciones como legítimas tendría una accuracy muy elevado, pero sería inútil para detectar fraude.

Por este motivo, en este proyecto la accuracy no se considera suficiente para evaluar el rendimiento de los modelos. En problemas de detección de fraude, las métricas más relevantes son:

MÉTRICA	UTILIDAD EN EL PROYECTO
Accuracy	Mide el porcentaje total de aciertos, aunque puede ser engañosa en datasets desbalanceados.
Precisión	Indica cuántas transacciones clasificadas como fraude realmente lo son.
Recall	Indica cuántos fraudes reales consigue detectar el modelo.
F1-score	Combina precisión y recall en una sola métrica.
AUC-ROC	Mide la capacidad global del modelo para distinguir entre fraude y no fraude.

Tabla 4: Métricas empleadas y sus utilidades

El recall resulta muy importante porque un falso negativo implica que una transacción fraudulenta no ha sido detectada. En un entorno financiero en la realidad, este tipo de error puede generar pérdidas económicas. Por tanto, el análisis no debe centrarse solo en cuántas transacciones se clasifican bien en total, sino en qué tipo de errores comete el modelo.

5.4. PREPROCESAMIENTO DE LOS DATOS

Antes de entrenar los modelos, se aplicaron varias transformaciones al dataset con el objetivo de preparar los datos y mejorar el rendimiento de los algoritmos.

5.4.1. ESCALADO DE LA VARIABLE AMOUNT

La variable Amount representa el importe económico de la transacción. Esta variable puede presentar valores en una escala muy distinta a las variables V1 a V28. Este aspecto es muy importante en modelos basados en distancias como KNN. Si una variable tiene valores mucho

más grandes que las demás, puede dominar el cálculo de distancias y hacer que el modelo le dé más importancia de la adecuada.

Para evitar este problema, la variable Amount se estandarizó mediante StandardScaler, transformándola para que tuviera media 0 y desviación típica 1. La fórmula general de la estandarización es:

$$Amount_{scaled} = \frac{(Amount - \mu)}{\sigma}; \text{ donde } \mu = \text{media de la variable, y } \sigma = \text{desviación típica.}$$

Ecuación 3: Fórmula de estandarización

Con esta transformación, el importe de la transacción queda en una escala comparable al resto de variables. Esto permite que los modelos trabajen de forma más equilibrada y evita que una única variable domine el proceso de aprendizaje.

5.4.2. ELIMINACIÓN DE LA VARIABLE TIME

La variable Time fue eliminada del dataset antes del entrenamiento, debido a que esta variable no representa una característica directa de la transacción, sino el instante en el que se produjo. Aunque podría ser útil en un análisis temporal más avanzado, en este proyecto no se trabaja con series temporales ni con evolución del comportamiento a lo largo del tiempo. Por tanto, se elimina para simplificar el modelo y evitar que introduzca información poco relevante para la clasificación. Tras su eliminación, el modelo trabaja con las variables V1 a V28, la variable Amount ya escalada y la variable objetivo Class.

5.4.3. SEPARACIÓN ENTRE VARIABLES INDEPENDIENTES Y OBJETIVO

Una vez aplicadas las transformaciones iniciales, se separa el conjunto de datos en dos partes: variables independientes y variable objetivo. Esta separación es necesaria porque los modelos deben aprender a partir de las características de cada transacción, pero sin tener acceso directo a la respuesta que se quiere predecir.

Las variables independientes son las que se utilizan como entrada del modelo, es decir, las características que describen cada operación. En este caso, tras eliminar la variable Time, se mantienen las variables V1 a V28 y Amount ya escalada. Estas variables forman el conjunto X .

Por otro lado, la variable objetivo es Class, que indica si la transacción es legítima o fraudulenta. Esta variable forma el conjunto y , que será utilizado para entrenar y evaluar los modelos.

ELEMENTO	VARIABLES INCLUIDAS	FUNCIÓN
X	V1 a V28 y Amount	Variables usadas para predecir
y	Class	Resultado real que se quiere predecir

Tabla 5: Separación de variables independientes y objetivo

Esta separación también evita que se produzca una fuga de información y el modelo utilice la propia respuesta como parte de los datos de entrada. Si esto ocurriera, los resultados serían artificialmente buenos, pero no válidos.

Esta fase permite definir correctamente el problema de clasificación supervisada: el modelo recibe las características de una transacción y aprende a predecir si pertenece a la clase fraudulenta o legítima.

5.5. BALANCEO DEL CONJUNTO DE DATOS

Debido al fuerte desbalance existente en el dataset original, se aplicó una técnica de submuestreo de la clase mayoritaria. Lo que se quería conseguir era reducir el número de transacciones legítimas para que la proporción entre clases sea menos desigual.

Primero, se separaron las transacciones fraudulentas y las transacciones normales. Después, se mantuvieron todas las transacciones fraudulentas disponibles, ya que son la clase minoritaria y la más importante para el estudio. A continuación, se seleccionó un número aleatorio de transacciones normales equivalente al triple del número de transacciones fraudulentas: por cada transacción fraudulenta se conservaron tres transacciones legítimas. Finalmente, se unieron ambos subconjuntos para formar un nuevo dataset balanceado.

Con este procedimiento se consigue una proporción aproximada de:

CLASE	PROPORCIÓN APROXIMADA TRAS BALANCEO
Transacciones fraudulentas	25%
Transacciones legítimas	75%

Tabla 6: Proporción tras balanceo de datos

Esta decisión permite mantener una mayoría de operaciones normales, como en la realidad pero reduciendo el desbalance extremo del dataset original. El objetivo de este balanceo es que los modelos puedan aprender patrones asociados al fraude sin verse completamente dominados por la clase mayoritaria. No obstante, esto también tiene límites: al eliminar muchas transacciones normales, se pierde información del dataset original. Por tanto, el modelo se entrena sobre un conjunto más equilibrado, pero menos representativo de la distribución real al completo. Aun así, es la opción para el proyecto, ya que permite mejorar la capacidad de detección de fraude y facilita la comparación entre los modelos.

5.6. DIVISIÓN DEL CONJUNTO EN ENTRENAMIENTO Y PRUEBA

Una vez preparado el dataset balanceado, se dividió en dos subconjuntos:

SUBCONJUNTO	PORCENTAJE	FUNCIÓN
Entrenamiento	70%	Ajustar los modelos
Prueba	30%	Evaluar el rendimiento con datos no vistos

Tabla 7: División en entrenamiento y prueba

El conjunto de entrenamiento se utiliza para que los modelos aprendan los patrones existentes en los datos, y el conjunto de prueba se reserva para comprobar cómo se comportan los modelos ante transacciones que no han visto durante el entrenamiento.

En este proyecto se ha utilizado una división 70/30 porque permite mantener un equilibrio adecuado entre aprendizaje y evaluación. El 70% proporciona al modelo una cantidad suficiente de datos para entrenarse, mientras que el 30% deja una muestra lo bastante amplia como para comprobar si las predicciones son fiables sobre nuevos datos.

Esta separación es clave para evaluar la capacidad de generalización. Si un modelo funciona bien en entrenamiento, pero mal en prueba, podría estar sobreajustado. Pero si mantiene un buen rendimiento en los datos de prueba, significa que ha aprendido patrones útiles y no solo los ejemplos concretos del entrenamiento. También se fija una semilla aleatoria para que la división sea reproducible. Esto permite obtener los mismos resultados cada vez que se ejecuta el procedimiento, facilitando la comparación entre modelos.

5.7. MODELO DE REGRESIÓN LOGÍSTICA

El primer modelo implementado fue la Regresión Logística. Este algoritmo es adecuado para problemas de clasificación binaria, ya que permite estimar la probabilidad de que una observación pertenezca a una clase determinada. La Regresión Logística estima la probabilidad de que una transacción sea fraudulenta a partir de las variables de entrada.

El modelo se entrena utilizando el conjunto de entrenamiento, ajustando los coeficientes asociados a cada variable para separar lo mejor posible las transacciones fraudulentas de las legítimas. Durante este proceso, el algoritmo aprende qué patrones de los datos están más relacionados con cada una de las clases.

En la implementación se aumentó el número máximo de iteraciones del algoritmo para asegurar que el proceso de optimización pudiera converger correctamente. Esta decisión fue importante porque, al trabajar con varias variables y un problema de clasificación con fraude, el modelo puede necesitar más iteraciones para encontrar una solución estable.

Una vez entrenado, el modelo proporciona dos salidas principales:

1. La clase predicha para cada transacción: legítima o fraudulenta.
2. La probabilidad estimada de fraude para cada transacción.

La primera salida permite calcular la matriz de confusión y las métricas de clasificación, como accuracy, precisión, recall y F1-score. La segunda salida permite calcular la curva ROC y el AUC, ya que estas métricas necesitan trabajar con las probabilidades estimadas.

Aquí el uso de Regresión Logística tiene una gran ventaja que es su interpretabilidad. Los coeficientes del modelo permiten analizar qué variables tienen mayor influencia en la predicción. Aunque las variables V1 a V28 no tengan un significado directo porque están anonimizadas, sí se puede estudiar cuáles tienen más peso matemático en la clasificación.

Esto indica que este modelo resulta adecuado para el proyecto porque combina buen rendimiento predictivo con facilidad de interpretación. Además, al ofrecer probabilidades de fraude permite analizar las transacciones no solo como fraudulentas o legítimas sino también según su nivel de riesgo.

5.8. MODELO DE K-NEAREST NEIGHBORS

El segundo modelo implementado fue K-Nearest Neighbors. Este algoritmo clasifica una nueva observación en función de las clases de sus vecinos más cercanos dentro del espacio

de características. A diferencia de la Regresión Logística, KNN no construye una función matemática durante el entrenamiento, sino que compara una nueva transacción con las transacciones ya conocidas y asigna la clase mayoritaria entre sus vecinos más próximos.

En este proyecto se utilizó KNN con 5 vecinos. Su elección se debe a que es un valor habitual como punto de partida en problemas de clasificación, ya que permite evitar que el modelo sea demasiado sensible a casos aislados y, al mismo tiempo mantener suficiente capacidad para detectar patrones locales.

Si se utilizara un valor de k demasiado bajo como 1 el modelo podría verse muy afectado por ruido o transacciones atípicas. O si se utilizara un valor demasiado alto, el modelo podría suavizar demasiado la clasificación y perder capacidad para detectar fraudes. Por ello, $k = 5$ se considera una elección intermedia adecuada para comparar el comportamiento de KNN frente a la Regresión Logística.

Este modelo puede resultar útil porque es capaz de detectar patrones locales en los datos. No necesita asumir una relación lineal entre las variables. Esto puede ser interesante en un problema de fraude, ya que algunas operaciones fraudulentas pueden parecerse entre sí aunque no sigan una estructura sencilla.

Sin embargo, KNN también presenta algunas limitaciones. Al basarse en la cercanía entre observaciones, es muy sensible a la escala de las variables. Debido a esto, el escalado de la variable Amount es muy importante, ya que evita que el importe de la transacción tenga más peso del adecuado al calcular la similitud.

Una vez entrenado, el modelo proporciona las dos mismas salidas principales que en Regresión Logística. Destacan en la segunda salida la curva ROC y el AUC ya que facilita comparar su capacidad discriminativa con la Regresión Logística.

KNN se ha incluido en el proyecto como un modelo alternativo basado en similitud. Su comparación con la Regresión Logística permite analizar dos enfoques distintos: uno probabilístico e interpretable, y otro basado en la cercanía entre transacciones.

5.9. EVALUACIÓN DE LOS MODELOS

Para evaluar el rendimiento de los modelos se han utilizado varias métricas de clasificación. En primer lugar, se calculó la matriz de confusión, que permite observar cuántas transacciones han sido clasificadas correctamente y cuántas se han clasificado de forma errónea. La matriz de confusión en un problema binario tiene la siguiente estructura:

	PREDICCIÓN: NO FRAUDE	PREDICCIÓN: FRAUDE
REAL: NO FRAUDE	Verdaderos negativos	Falsos positivos
REAL: FRAUDE	Falsos negativos	Verdaderos positivos

Tabla 8: Estructura de una matriz de confusión

- Verdaderos positivos: fraudes correctamente detectados
- Falsos negativos: fraudes que el modelo no detecta
- Falsos positivos: transacciones legítimas clasificadas erróneamente como fraude
- Verdaderos negativos: transacciones legítimas correctamente clasificadas

A partir de esta matriz se obtienen las siguientes métricas:

- $accuracy = \frac{VP + VN}{VP + VN + FP + FN}$
- $precision = \frac{VP}{VP + FP}$
- $recall = \frac{VP}{VP + FN}$
- $F1 - score = 2 \cdot \frac{precision \cdot recall}{precision + recall}$

Ecuación 4: Fórmulas de métricas de clasificación: accuracy, precision, recall, F1-score

En el contexto del fraude financiero, el recall tiene una importancia significativa porque mide la capacidad del modelo para detectar los fraudes reales. Un recall bajo implicaría que muchas operaciones fraudulentas pasarían desapercibidas.

También se calcula el AUC, que mide la capacidad del modelo para distinguir entre las dos clases. Cuanto más cercano sea su valor a 1, mayor será la capacidad discriminativa del modelo. La curva ROC permite representar gráficamente la relación entre la tasa de verdaderos positivos y la tasa de falsos positivos para distintos umbrales de decisión.

5.10. MEJORA DE LOS MODELOS FINALES

Una forma habitual de mejorar un modelo de clasificación binaria es ajustar el umbral de decisión. Este umbral es el valor a partir del cual el modelo clasifica una transacción como

fraudulenta. Normalmente se utiliza un umbral de 0,5 de forma que si la probabilidad estimada de fraude es superior al 50 %, la operación se clasifica como fraude, y si es inferior, como legítima.

En la detección de fraude, este umbral es especialmente importante porque los errores no tienen el mismo impacto. Un falso positivo lleva a marcar como fraudulenta una transacción legítima, mientras que un falso negativo lleva a no detectar un fraude real. En un entorno financiero este segundo caso suele ser más grave ya que puede generar graves pérdidas económicas. Por ello, en este tipo de problemas puede interesar reducir el umbral para detectar más fraudes, aunque aumente el número de falsas alarmas.

Tanto la Regresión Logística como KNN permiten obtener una probabilidad asociada a la clase fraudulenta. Esto hace posible analizar cómo cambiaría el comportamiento de los modelos si se modificase el umbral de decisión. Si el umbral se reduce entonces el modelo será más sensible y clasificará más transacciones como posible fraude de manera que aumenta el recall. Sin embargo, esto también puede provocar que algunas operaciones legítimas sean clasificadas erróneamente como fraudulentas.

Para estudiar este comportamiento se emplea la curva ROC, que permite analizar la relación entre la tasa de verdaderos positivos y la tasa de falsos positivos para distintos valores de umbral. Así no se evalúa el modelo solo con un punto fijo de decisión, sino que se observa su capacidad para separar transacciones legítimas y fraudulentas.

En este proyecto se mantiene el umbral estándar para comparar ambos modelos en las mismas condiciones, lo que permite que la Regresión Logística y KNN sean evaluados de igual forma sin favorecer a ninguno de los dos.

Por ende, una posible forma de mejorar los modelos finales sería ajustar el umbral de decisión para adaptarlo mejor al objetivo del problema. En un sistema real de detección de fraude, este ajuste podría depender de la política de riesgo de la entidad financiera: si se quiere evitar al máximo que se escape un fraude, se podría reducir el umbral; si se busca minimizar las falsas alarmas, podría mantenerse o incluso aumentarse.

6. RESULTADOS

En este apartado se recogen los resultados obtenidos tras la aplicación de los distintos modelos de clasificación propuestos. El análisis está estructurado agrupando los resultados de cada modelo, lo que permite evaluar de forma comparativa el rendimiento de los enfoques utilizados y seleccionar, en cada caso, aquel que presenta una mayor eficacia según las métricas establecidas.

Para los modelos seleccionados, se analiza su comportamiento en el contexto de clasificación de transacciones fraudulentas con un fuerte desbalanceo de clases. El objetivo es comparar su capacidad de detección prestando atención no solo a la precisión global, sino también al impacto de los errores críticos, sobre todo los falsos negativos, debido a su elevada relevancia en este tipo de problemas.

Con esta estructura, se busca proporcionar una visión completa del rendimiento de los modelos, así como justificar de manera objetiva la validez de las soluciones propuestas en la detección de fraude.

6.1. RESULTADOS DEL MODELO DE REGRESIÓN LOGÍSTICA

El modelo de regresión logística ha mostrado un rendimiento muy elevado en la detección de fraude por la obtención de resultados consistentes en todas las métricas evaluadas. Esto indica que el modelo es capaz de distinguir con eficacia entre transacciones legítimas y fraudulentas.

Los resultados obtenidos son los siguientes:

- **Accuracy:** 0.96
- **Precisión:** 0.94
- **Recall:** 0.91
- **F1-score:** 0.93
- **AUC:** 0.9815

	precisión	recall	f1-score	support
0	0,97	0,98	0,98	441
1	0,94	0,91	0,93	150
accuracy			0,96	591
macro avg	0,96	0,94	0,95	591
weighted avg	0,96	0,96	0,96	591
AUC	0,98151171579743			

Tabla 9: Resultados del modelo con Regresión Logística

La accuracy del 96% indica que el modelo realiza predicciones correctas en la gran mayoría de los casos pero en problemas de fraude esta métrica no es la más relevante, ya que puede verse influenciada por el desbalance.

La precisión indica que de todas las transacciones clasificadas como fraude, el 94% son realmente fraudulentas. Esto consigue un bajo número de falsos positivos y así reduce las alertas innecesarias.

El recall es la métrica más importante en este contexto, ya que indica que el modelo es capaz de detectar el 91% de los fraudes reales. Esto significa que solo el 9% de los fraudes pasan desapercibidos, lo cual es un gran resultado dado el impacto económico que puede tener no detectarlo.

El F1-score del 93% muestra un buen equilibrio entre precisión y recall.

Por último, el valor de AUC de 0.9815 refleja una excelente capacidad de discriminación. El modelo es muy eficaz separando las clases de fraude y no fraude independientemente del umbral utilizado.

6.2. RESULTADOS DEL MODELO K-NEAREST NEIGHBORS

El modelo K-Nearest Neighbors también presenta un rendimiento elevado en la detección de fraude, aunque ligeramente inferior al modelo de regresión logística en algunos aspectos clave relacionados con la capacidad de detección de casos positivos.

Al contrario que modelos paramétricos como la regresión logística, KNN es un algoritmo que realiza las predicciones en función de la similitud entre observaciones. Esto puede hacerlo más sensible a la distribución de los datos y al ruido, y aún mas con presencia de clases desbalanceadas como la detección de fraude.

Las métricas obtenidas son las siguientes:

- **Accuracy:** 0.96
- **Precisión:** 0.96
- **Recall:** 0.89
- **F1-score:** 0.92
- **AUC:** 0.9637

	precisión	recall	f1-score	support
0	0,96	0,99	0,98	441
1	0,96	0,89	0,92	150
accuracy			0,96	591
macro avg	0,96	0,94	0,95	591
weighted avg	0,96	0,96	0,96	591
AUC	0,9636885865457294			

Tabla 10: Resultados del modelo con KNN

La accuracy del 96% indica que este modelo clasifica al igual la gran mayoría de las observaciones. Sin embargo, como en regresión logística, esta métrica por sí sola no refleja bien el rendimiento en problemas de fraude por el desbalance entre clases.

La precisión es el punto fuerte de este modelo, ya que predice que el 96% de las transacciones clasificadas como fraude son realmente fraudes. Esto implica que el modelo genera muy pocas falsas alarmas reduciendo las revisiones innecesarias.

El recall de 0.89 es inferior al obtenido por la regresión logística. Esto significa que el modelo es menos eficiente a la hora de detectar fraudes reales dejando escapar un 11% de los casos fraudulentos. Esta métrica no favorece al KNN ya que implica un mayor riesgo económico.

El F1-score del 92% es ligeramente inferior al modelo de regresión logística, lo que indica un rendimiento global sólido pero no óptimo.

Por último, el valor de AUC de 0.9637 indica una buena capacidad de discriminación entre clases pero inferior al modelo logístico. Esto deja claro que KNN separa correctamente las clases pero con menor eficiencia en los márgenes de decisión.

6.3. COMPARACIÓN DE MODELOS

La comparación entre el modelo de regresión logística y el modelo K-Nearest Neighbors (KNN) permite ver algunas diferencias en su comportamiento, en esencia en cómo gestionan la detección de fraude.

En primer lugar, ambos modelos alcanzan una accuracy idéntica (0.96), lo que indica que los dos funcionan bastante bien clasificando las transacciones. Pero como se ha explicado previamente, esta métrica no es suficiente para evaluar cuál es mejor ya que no tiene en cuenta el tipo de errores que se cometen.

Una de las diferencias más importantes aparece en el recall, en el que la regresión logística obtiene un valor mayor (0.91 frente a 0.89); y así detecta un mayor número de fraudes reales. En un problema real donde cada fraude no detectado supone pérdidas económicas este aspecto es crucial.

Por otro lado, el modelo KNN destaca en precisión (0.96 frente a 0.94). Esto se traduce en que cuando el modelo predice que una transacción es fraudulenta, suele acertar con más frecuencia. Es un punto a favor para el KNN porque significa que habrá menos falsas alarmas.

En cuanto al AUC, la regresión logística vuelve a ganar (0.9815 frente a 0.9637), lo que indica que tiene una mejor capacidad para distinguir entre fraude y no fraude.




Figura 3: Comparación entre ambos modelos basada en recall y precisión

6.4. ANÁLISIS DE MATRICES DE CONFUSIÓN

Las matrices de confusión permiten entender mejor cómo se comportan realmente los modelos, más allá de lo que indican las métricas globales.

En ambos modelos se observa que la gran mayoría de las transacciones legítimas se clasifican correctamente, lo que indica que los dos modelos funcionan bien a la hora de identificar operaciones normales. Sin embargo, los errores aparecen en mayor medida en la detección de fraude que justamente es la parte crítica del problema.

Al comparar los modelos se pueden ver algunas diferencias importantes. Por un lado, la regresión logística presenta un menor número de falsos negativos (14), lo que significa que se pierden menos fraudes. Por otro lado, el modelo KNN tiene menos falsos positivos (6) por lo que genera menos alertas incorrectas y menos revisiones adicionales.

A pesar de esto, los falsos negativos tienen un impacto mucho mayor que los falsos positivos. Por ello, este análisis refuerza la idea de que la regresión logística es una opción más adecuada, ya que prioriza la detección de fraude incluso a costa de generar alguna alerta adicional.




Figura 4: Análisis de las matrices de confusión de ambos modelos

6.5. CURVA ROC Y CAPACIDAD DISCRIMINATIVA

La curva ROC es una herramienta muy útil para analizar cómo se comporta un modelo de clasificación con variaciones en el umbral de decisión. En lugar de evaluar el modelo con un único punto la curva ROC permite ver su rendimiento de forma global.

Esta curva representa la relación entre recall y la tasa de falsos positivos para distintos valores de umbral. De esta forma se observa cómo cambia la capacidad del modelo para detectar fraudes frente al número de falsas alarmas.

En la comparación de modelos, la curva ROC se sitúa claramente por encima de la diagonal, lo que indica que los dos tienen una buena capacidad de clasificación. La diagonal representa el comportamiento de un modelo aleatorio, por lo que estar por arriba significa que los modelos están aprendiendo patrones útiles en los datos.

Sin embargo, al comparar las curvas se observa que la correspondiente a la regresión logística se mantiene ligeramente por encima de la de KNN en la mayoría de los puntos. Cuando esto ocurre significa que la regresión logística consigue un mejor equilibrio entre detección de fraude y generación de falsos positivos.

Esta diferencia también se refleja en el valor del AUC. La regresión logística alcanza un AUC de 0.9815 mientras que KNN obtiene un valor de 0.9637. Aunque ambos resultados son altos, el modelo logístico presenta una capacidad discriminativa superior.

En términos prácticos esto significa que la regresión logística es más eficaz a la hora de distinguir entre transacciones fraudulentas y legítimas de forma global, independientemente del umbral que se utilice para tomar decisiones.




Figura 5: Comparación de modelos con la curva ROC

6.6. ANÁLISIS CRÍTICO DE LOS RESULTADOS

Los resultados obtenidos muestran que ambos modelos son válidos para la detección de fraude en transacciones financieras por sus altos valores en todas las métricas analizadas. Hecho muy destacable teniendo en cuenta que se trata de un problema con desbalanceo de clases. Debido a los buenos resultados se puede confirmar que el preprocesamiento aplicado ha sido adecuado y ha permitido a los modelos aprender patrones útiles.

Aun así, al analizar los resultados con más detalle se aprecian diferencias significativas. La regresión logística muestra un comportamiento más equilibrado con mejor recall y AUC. Traducido en una mayor capacidad para detectar fraudes y en una mejor separación entre las dos clases. En cambio, el KNN obtiene un recall algo más bajo lo que lleva a dejar escapar más casos de fraude.

Además, el comportamiento de KNN depende en mayor medida de cómo estén distribuidos los datos. Al basarse en la proximidad entre observaciones, la presencia de ruido o del número de vecinos pueden influir bastante en su rendimiento, convirtiéndolo en un modelo menos estable. Por el contrario, la regresión logística suele ser más consistente en este tipo de situaciones.

Por otro lado, los resultados obtenidos encajan bastante bien con lo que se esperaba. Es habitual que estos modelos más simples funcionen muy bien cuando los datos están bien tratados. Que ambos modelos tengan valores altos de AUC sugiere que son capaces de diferenciar bien entre las clases en el conjunto de datos. También era previsible que KNN tuviera más dificultades con la clase minoritaria porque este tipo de algoritmos normalmente se ve más afectado por el desbalanceo.

A pesar de todo, han surgido ciertas limitaciones. Específicamente, usar submuestreo para equilibrar las clases puede hacer que el conjunto de datos deje de reflejar la realidad. Aunque esta técnica ayuda a entrenar mejor los modelos, también puede provocar que el rendimiento observado no sea el mismo en un entorno real.

Finalmente los resultados, como se esperaba, apuntan a que la regresión logística es una opción más sólida para este problema. Ofrece un buen equilibrio entre detección de fraude, precisión y estabilidad. Por su parte, KNN puede resultar útil en ciertos casos, sobre todo en los que se quiere reducir el número de falsas alarmas pero en este contexto concreto resulta menos adecuado.

7. CONCLUSIONES

Tras el desarrollo del proyecto y una vez analizados los resultados obtenidos, se pueden establecer una serie de conclusiones relacionadas con el cumplimiento de los objetivos planteados al inicio de la memoria. El propósito principal del trabajo era diseñar e implementar un sistema de clasificación supervisada para la detección de fraude en transacciones financieras, utilizando dos modelos diferentes: Regresión Logística y K-Nearest Neighbors. A partir de los resultados obtenidos, se puede afirmar que el objetivo se ha cumplido, ya que ambos modelos han sido entrenados, evaluados y comparados mediante métricas adecuadas para este tipo de problema.

Antes de comenzar la parte técnica, se realizó una investigación previa sobre el fraude financiero y las principales técnicas utilizadas para su detección. Esta revisión permitió comprender que el fraude en transacciones digitales es un problema complejo, caracterizado por un fuerte desbalance entre operaciones legítimas y fraudulentas, así como el impacto que tienen los errores de clasificación. Específicamente, se comprobó que los falsos negativos son muy relevantes, ya que representan fraudes reales que no han sido detectados por el sistema.

En cuanto al conjunto de datos, se trabajó con el dataset *Credit Card Fraud Detection* de Kaggle, formado por transacciones financieras etiquetadas. Este permitió plantear el problema como una tarea de clasificación binaria supervisada, donde la variable objetivo indica si una transacción es legítima o fraudulenta. A pesar de ello, también se identificaron limitaciones, como que las variables V1 a V28 se encuentran anonimizadas, lo que impide conocer su significado real. Aun así han resultado útiles ya que contienen información suficiente para que los modelos puedan detectar patrones asociados al fraude.

Uno de los aspectos más importantes del proyecto ha sido el tratamiento del desbalance de clases. En el dataset original las transacciones fraudulentas representaban un 0,17 % del total, por lo que entrenar los modelos directamente sobre los datos originales podría haber provocado una inclinación excesiva hacia la clase mayoritaria. Para solventar el problema, se llevó a cabo un submuestreo, manteniendo todas las transacciones fraudulentas y seleccionando una muestra de operaciones normales, lo que permitió obtener un conjunto de datos más equilibrado y facilitar el aprendizaje de los modelos, pero asumiendo pérdida de información respecto al dataset original.

En cuanto al preprocesamiento, la eliminación de la variable Time permitió simplificar el conjunto de datos ya que el proyecto no se centraba en un análisis temporal. Además, el escalado de la variable Amount ha sido importante para KNN, debido a que este algoritmo se basa en la distancia entre observaciones, evitando de esta manera que el importe de la transacción tuviese un peso excesivo frente al resto de variables.

Respecto a los modelos implementados, como esperábamos, ambos han ofrecido resultados positivos. La Regresión Logística ha demostrado que es un modelo estable, muy fácil de interpretar y eficaz para la detección de fraude. Sus resultados muestran un buen equilibrio entre precisión, recall y AUC, destacando su capacidad para detectar fraudes reales. Además, al tratarse de un modelo probabilístico permite interpretar la salida como una probabilidad de fraude, algo muy útil en el contexto financiero.

Por otro lado, el modelo K-Nearest Neighbors también ha obtenido un rendimiento elevado, sobre todo en precisión. Lo que quiere decir que cuando clasifica una transacción como fraudulenta, acierta con bastante frecuencia. Pero su recall es un poco inferior al de la Regresión Logística, lo que da lugar a dejar pasar un número mayor de fraudes reales. Además, KNN depende más de la distribución de los datos y de la escala de las variables, por lo que puede considerarse menos estable.

Al comparar los resultados de ambos modelos se puede concluir que la Regresión Logística es una opción más adecuada para el problema planteado. KNN presenta una precisión ligeramente superior pero la Regresión Logística obtiene un mejor recall y un mayor AUC. En detección de fraude financiero, esta diferencia es importante ya que resulta prioritario reducir el número de fraudes no detectados. Por tanto, el modelo logístico ofrece un mayor equilibrio entre capacidad de detección, estabilidad e interpretabilidad.

También se ha comprobado que la accuracy, a pesar de alcanzar valores altos en ambos modelos no puede considerarse la métrica principal en este tipo de problemas debido al desbalance, ya que una accuracy elevada puede ocultar errores importantes en la clase minoritaria. Por ello, métricas como el recall, la precisión, el F1-score y el AUC han sido más útiles para valorar correctamente su comportamiento.

Al fijarse en los objetivos específicos, se puede afirmar que se han cumplido de forma general. Se ha analizado el problema del fraude financiero, se ha seleccionado y estudiado un conjunto de datos, y a partir de ello se han implementado dos modelos de clasificación supervisada y comparado sus resultados mediante métricas apropiadas. Todo ello seguido de un análisis de las variables más influyentes dentro del modelo de Regresión Logística, aunque la interpretación de dichas variables se ha encontrado limitada por la anonimización del dataset.

Como conclusión final, el proyecto demuestra que los modelos de clasificación supervisada pueden ser herramientas útiles para la detección de fraude en transacciones financieras. En concreto, la Regresión Logística se presenta como una alternativa sólida cuando se busca combinar buen rendimiento predictivo con interpretabilidad. Los resultados se entienden dentro de las limitaciones del proyecto, especialmente por el uso de un dataset ya existente,

el tratamiento del desbalance mediante submuestreo y la imposibilidad de interpretar directamente gran parte de las variables.

Por último, el desarrollo de este trabajo ha permitido comprender de forma más profunda el proceso completo de construcción de un sistema de detección de fraude: desde el análisis del problema y el tratamiento de los datos hasta el entrenamiento, evaluación y comparación de modelos. Esto ha permitido tanto aplicar técnicas de Machine Learning como entender la importancia de tomar decisiones adecuadas en cada fase del proceso para obtener resultados fiables y útiles en un contexto real.

8. BIBLIOGRAFÍA

- [1] K. D. Fuentes-Castro, S. Ruiz-Bernal, y J. S. Reyes-Gélvez, “Guía orientada para la disminución de posibles fraudes en transacciones de NFTS en Cúcuta,” *Reflexiones Contables*, vol. 7, no. 2, pp. 29–35, 2024, doi: <https://doi.org/10.22463/26655543.4570>
- [2] L. Ferrando y D. Posada, “Uso del efectivo y otros medios de pago: ¿cómo está cambiando la forma en que pagamos?,” *Boletín Económico*, Banco de España, no. 2023/T1, 2023, pp. 1–?, doi: <https://doi.org/10.53479/24994>
- [3] A. Rodríguez Zárate, “Análisis económico de la responsabilidad bancaria frente a los fraudes electrónicos: el riesgo provecho, el riesgo creado y el riesgo profesional,” *Vniversitas*, vol. 63, no. 128, pp. 285–314, 2014, doi: <https://doi.org/10.11144/Javeriana.VJ128.aerb>
- [4] A. A. Compagnino, Y. Maruccia, S. Cavuoti, G. Riccio, A. Tutone, R. Crupi y A. Pagliaro, “An Introduction to Machine Learning Methods for Fraud Detection,” *Applied Sciences*, vol. 15, no. 21, Art. 11787, 2025, doi: <https://doi.org/10.3390/app152111787>
- [5] M. A. Castaño, J. L. C. Rincon y A. B. Sánchez, “Impact of artificial intelligence on financial decision making: opportunities and challenges for business leaders,” *Dyna*, vol. 91, no. 233, pp. 114–123, 2024, doi: <https://doi.org/10.15446/dyna.v91n233.114660>.
- [6] C. Dirican, “The Impacts of Robotics, Artificial Intelligence On Business and Economics,” *Procedia – Social and Behavioral Sciences*, vol. 195, pp. 564–573, 2015, doi: <https://doi.org/10.1016/j.sbspro.2015.06.134>
- [7] C. M. De La Torre Lascano y J. I. Quiroz Peña, “Cybercrime and its association in the commission of financial fraud in COVID-19 pandemic,” *Revista Venezolana de Gerencia*, vol. 28, no. 102, pp. 609–628, 2023, doi: <https://doi.org/10.52080/rvgluz.28.102.11>
- [8] V. Díaz Agudelo, M. C. Osorno Gallego, L. Tangarife Gómez y C. Chamorro González, “Componentes que influyen en la ejecución de fraudes financieros: percepción de los profesionales contables,” *Semestre Económico*, vol. 24, no. 56, pp. 105–124, 2021, doi: <https://doi.org/10.22395/seec.v24n56a4>.

- [9] J. B. Tustón Fuentes y E. J. Macías Arias, “Modelos de machine learning para la detección de fraudes financieros: una revisión de la literatura,” *Unesum Ciencias*, vol. 9, no. 2, pp. 220–234, 2025, doi: <https://doi.org/10.47230/unesum-ciencias.v9.n2.2025.220-234>
- [10] A. A. Rizki, I. S. Prajitno y R. A. Wayasti, “Data mining application to detect financial fraud in Indonesia’s public companies,” en *Proc. 2017 3rd International Conference on Science in Information Technology (ICSITech)*, Bandung, Indonesia, 2017, pp. 206–211, doi: <https://doi.org/10.1109/ICSITech.2017.8257111>
- [11] J. C. Escanciano y J. Olmo, “Robust backtesting tests for value-at-risk models,” *Journal of Financial Econometrics*, vol. 9, no. 1, pp. 132–161, Winter 2011, doi: <https://doi.org/10.1093/jfinec/nbq021>.
- [12] V. N. Dornadula y S. Geetha, “Credit card fraud detection using machine learning algorithms,” *Procedia Computer Science*, vol. 167, pp. 1256–1265, 2020, doi: <https://doi.org/10.1016/j.procs.2020.01.057>.
- [13] R. C. Dávila-Morán, R. A. Castillo-Sáenz, A. R. Vargas-Murillo, L. V. Dávila, E. García-Huamantumba, C. F. García-Huamantumba, R. F. P. Cajas y C. E. G. Paredes, “Application of machine learning models in fraud detection in financial transactions,” *Data and Metadata*, vol. 2, Art. 109, 2023, doi: <https://doi.org/10.56294/dm2023109>
- [14] H. R. Ranganatha y A. Syed Mustafa, “Enhancing fraud detection efficiency in mobile transactions through the integration of bidirectional 3D Quasi-Recurrent Neural Network and blockchain technologies,” *Expert Systems with Applications*, vol. 249, Art. 125179, 2025, doi: <https://doi.org/10.1016/j.eswa.2024.125179>
- [15] M. Faridpour y A. Moradi, “A Novel Method for Detection of Fraudulent Bank Transactions using Multi-Layer Neural Networks with Adaptive Learning Rate,” *International Journal of Nonlinear Analysis and Applications*, vol. 11, no. 2, pp. 437–445, 2020, doi: <https://doi.org/10.22075/ijnaa.2020.4576>
- [16] Nachiappan B., Rajkumar N., Viji C. y Mohanraj A., “Artificial and Deceitful Faces Detection Using Machine Learning,” en *SCT Proceedings in Interdisciplinary Insights and Innovations*, vol. 3, Art. 611, 2024, doi: <https://doi.org/10.56294/sctconf2024611>
- [17] V. Van Vlasselaer, C. Bravo, O. Caelen, T. Eliassi-Rad, L. Akoglu, M. Snoeck y B. Baesens, “APATE: A novel approach for automated credit card transaction fraud detection using network-based extensions,” *Decision Support Systems*, vol. 75, pp. 38–48, 2015, doi: <https://doi.org/10.1016/j.dss.2015.04.013>
- [18] C. Cholevas, E. Angeli, Z. Sereti, E. Mavrikos y G. E. Tsekouras, “Anomaly Detection in Blockchain Networks Using Unsupervised Learning: A Survey,” *Algorithms*, vol. 17, no. 5, Art. 201, 2024, doi: <https://doi.org/10.3390/a17050201>
- [19] B. A. Khalaf, S. H. Othman, S. A. Razak y A. Konios, “A hybrid deep learning model for securing smart city networks against flooding attack,” *Journal of Cybersecurity and*

Information Management, vol. 14, no. 2, pp. 311–322, 2024, doi: <https://doi.org/10.54216/JCIM.1402224>

[20] J. J. Yao y Y. Ren, “Anomaly detection in financial transactions: privacy-preserving behavioral anomaly detection using graph neural networks on dynamic card transaction graphs,” en Proceedings, Web Information Systems Engineering, pp. 286–301, 2024, doi: https://doi.org/10.1007/978-981-96-0576-7_22

[21] Massimiliano Zanin, Miguel Romance, Santiago Moral y Regino Criado, “Credit Card Fraud Detection through Parenclitic Network Analysis,” Complexity, vol. 2018, pp. 1–9, 2018, doi: <https://doi.org/10.1155/2018/5764370>

[22] Ezekiel Udeh, Prisca Amajuoyi, Kudirat Bukola Adeusi y Anwulika Scott, “The role of big data in detecting and preventing financial fraud in digital transactions,” en Financial Fraud: A Literature Review, chap. 4, Wiley, 2024, doi: <https://doi.org/10.1002/9781119565178.ch4>.

[23] Balusamy Nachiappan, N. Rajkumar, C. Viji y A. Mohanraj, “Artificial and Deceitful Faces Detection Using Machine Learning,” Salud, Ciencia y Tecnología – Serie de Conferencias, vol. 3, p. 611, 2024, doi: <https://doi.org/10.56294/sctconf2024611>.

[24] Massimiliano Zanin, Miguel Romance, Santiago Moral y Regino Criado, “Anomaly Detection in Blockchain Networks Using Unsupervised Learning: A Survey,” Algorithms, vol. 17, no. 5, Art. 201, 2024, doi: <https://doi.org/10.3390/a17050201>.

[25] V. Van Vlasselaer, C. Bravo, O. Caelen, T. Eliassi-Rad, L. Akoglu, M. Snoeck y B. Baesens, “APATE: A novel approach for automated credit card transaction fraud detection using network-based extensions,” Decision Support Systems, vol. 75, pp. 38–48, 2015, doi: <https://doi.org/10.1016/j.dss.2015.04.013>.

[26] H. R. Ranganatha y A. Syed Mustafa, “Enhancing fraud detection efficiency in mobile transactions through the integration of bidirectional 3D Quasi-Recurrent Neural Network and blockchain technologies,” Expert Systems with Applications, vol. 260, Art. 125179, 2025, doi: <https://doi.org/10.1016/j.eswa.2024.125179>

[27] M. Faridpour y A. Moradi, “A novel method for detection of fraudulent bank transactions using multi-layer neural networks with adaptive learning rate,” International Journal of Nonlinear Analysis and Applications, vol. 11, no. 2, pp. 437–445, 2020, doi: <https://doi.org/10.22075/ijnaa.2020.4576>

[28] J. J. Yao y Y. Ren, “Anomaly detection in financial transactions: privacy-preserving behavioural anomaly detection using graph neural networks on dynamic card transaction graphs,” en Proceedings, Web Information Systems Engineering, pp. 286–301, 2024, doi: <https://doi.org/10.1007/s11704-024-40474-y>

[29] T. Cao, M. D. Petersen, C. H. Cramer, T. R. Toppozada, M. S. Reichle y J. F. Davis, “The calculation of expected loss using probabilistic seismic hazard,” Bulletin of the Seismological

Society of America, vol. 89, no. 4, pp. 867–876, 1999, doi:
<https://doi.org/10.1785/BSSA0890040867>

[30] Referencia de libro académico (IEEE): M. D. Carrera, R. C. Dubois, C. H. Edwards, R. T. Fletcher, J. G. Hagan y S. D. Naidu, The Calculation of Expected Loss Using Probabilistic Seismic Hazard, Society of Exploration Geophysicists, 1999, doi:
<https://doi.org/10.1561/20000000004>

ANEXO: CÓDIGO

A continuación, se pone a disposición el código programado en Python para la resolución del proyecto:

<https://drive.google.com/drive/folders/15nZONph2SUIwwOoWaNX7vhRfAOouVxmg?usp=sharing>

